

# TP7 NLP – Eco-Smart Classifier

**Module :** Extraction de caractéristiques techniques à partir de rapports de collecte

## 1. Contexte du Projet

Le projet **Eco-Smart** vise à classifier des déchets et estimer leur valeur de revente. Le dataset contient une colonne textuelle cruciale : `Rapport_Collecte`. Ce champ contient des informations souvent absentes des colonnes numériques (état du matériau, traces de contamination, provenance spécifique).

### Objectifs :

- Transformer le texte brut en caractéristiques exploitables par les modèles de Machine Learning.
- Comparer les approches statistiques classiques et les plongements lexicaux (embeddings).
- Automatiser l'extraction d'informations clés (Contamination, Rigidité, Type de matériau).

## Partie 1 – Prétraitement et Baseline Statistique

*Objectif : Nettoyer le texte "sale" du dataset et créer une première représentation numérique.*

### 1.1 Nettoyage et Normalisation du texte

1. **Analyse de la donnée :** Explorez la colonne `Rapport_Collecte`. Identifiez les bruits récurrents (ponctuation, stop-words techniques comme "kg", "poids", "provenance").
2. **Pipeline de nettoyage :** Développez une fonction de prétraitement incluant :
  - Mise en minuscule et suppression de la ponctuation.
  - Suppression des stop-words (français).
  - Lemmatisation (ex: "collecté", "collectés", "collectée"  $\rightarrow$  "collecte").
3. **Spécificité Eco-Smart :** Pourquoi est-il crucial de NE PAS supprimer les chiffres liés aux unités (ex: "45.8 kg") avant l'extraction ?

### 1.2 Vectorisation TF-IDF (Baseline)

1. **Mise en œuvre :** Appliquez un `TfidfVectorizer` sur les rapports nettoyés. Utilisez des n-grammes (1,2) pour capturer des concepts comme "haute conductivité" ou "légèrement translucide".
2. **Réduction de dimension :** Limitez à 500 features pour éviter le sur-apprentissage.

3. **Évaluation ML** : Utilisez ces vecteurs pour entraîner un classifieur simple (Random Forest ou SVM) afin de prédire la Catégorie du déchet. Analysez la matrice de confusion.

---

## Partie 2 – NLP Avancé et Multimodalité

---

*Objectif : Utiliser des modèles de langue pour enrichir le modèle de prédiction numérique.*

### 2.1 Plongements Lexicaux (Embeddings)

1. **Word2Vec vs TF-IDF** : Formez ou chargez un modèle Word2Vec sur vos rapports. Expliquez comment ce modèle parvient à lier sémantiquement "métal" et "conductivité".
2. **Sentence Transformers (Bonus Cahier des Charges)** : Utilisez un modèle comme CamemBERT pour transformer chaque rapport en un vecteur dense (embedding de phrase).

### 2.2 Extraction d'Attributs (Information Extraction)

À l'aide de techniques de recherche de motifs (Regex) ou de classification, extrayez du texte trois nouvelles colonnes numériques/catégorielles :

- **Contamination** : (Binaire : 1 si le texte mentionne "contamination", "humidité" ou "traces", 0 sinon).
- **État du matériau** : (Catégoriel : Neuf, Moyen, Brisé).
- **Source mentionnée** : (Extraction de l'usine si absente de la colonne Source).

### 2.3 Vers le modèle Multimodal (Fusion)

1. **Architecture de fusion** : Proposez une méthode pour combiner les features numériques (Poids, Volume) avec les features NLP (vecteurs BERT ou TF-IDF).
2. **Analyse de performance** : Le modèle multimodal est-il plus performant pour prédire le `Prix_Revente` que le modèle utilisant uniquement les chiffres ? Justifiez.

---

## Livrables

---

- **Script de Prétraitement** : Nettoyage robuste du champ `Rapport_Collecte`.
- **Comparaison** : Tableau comparatif des scores (Accuracy/F1) entre TF-IDF et Embeddings.
- **Journal de Prompts** : (Fichier `PROMPTS.md`) Justification des choix techniques et des interactions avec l'IA pour la génération du code.
- **Tracking** : Log des expériences de vectorisation sous MLflow.